

# Trabalho Prático III

## Aplicações Criativas de NLP e Transfer Learning

---

Prof. Cristiano L. Castro

2 de junho de 2026

### 1 CONTEXTUALIZAÇÃO E OBJETIVO

Neste último mês, exploramos o tema de Modelos de Linguagem, mais conhecido como Processamento de Linguagem Natural (NLP). Estudamos os modelos de linguagem baseados em Redes Neurais Recorrentes (RNNs) e a sua evolução até a arquitetura de *Transformers*.

Por meio de exemplos práticos em notebooks do Colab em Python, foi mostrado como implementar Redes Neurais Recorrentes (RNNs) e realizar *fine-tuning* de modelos de linguagem pré-treinados (como o BERT) para tarefas *downstream*, como Busca Semântica e Classificação de Texto. Tudo feito com PyTorch, modelos pré-treinados e bases de dados do *Hugging Face*.

Agora, o desafio é colocar esse conhecimento à prova no mundo real. O objetivo deste trabalho final é que vocês desenvolvam uma solução criativa de NLP baseada em **Transferência de Aprendizado** (*Transfer Learning*) para resolver um problema real, preferencialmente focado no ecossistema da nossa universidade (UFMG) ou em um domínio de grande impacto social e acadêmico.

O céu é o limite para a criatividade, mas o rigor técnico e metodológico será cobrado.

## 2 O DESAFIO

Cada grupo deve escolher uma base de dados (que pode ser minerada ou construída por vocês), definir uma tarefa específica e treinar/adaptar um modelo de linguagem para solucioná-la.

### 2.1 IDEIAS E INSPIRAÇÕES (FOCO NA UFMG)

Vocês são livres para propor qualquer tema, mas aqui estão algumas ideias para inspirá-los:

- **O “Guia do Calouro” (Q&A e Busca Semântica):** Ingressar na universidade é lidar com uma sopa de letrinhas e regras (CEPE, SIGA, trancamento, jubilamento). Que tal criar um assistente de busca semântica em que o calouro faça uma pergunta em linguagem natural e o modelo retorne o trecho exato da norma da UFMG que responde à dúvida?
- **Mapeamento da Ciência (Classificação/Clustering de TCCs):** Utilizando os resumos de Trabalhos de Conclusão de Curso ou Dissertações disponíveis no Repositório Institucional da UFMG, vocês podem treinar um modelo para prever a qual departamento o trabalho pertence, classificar a área de atuação ou elaborar um mapa semântico das pesquisas atuais da universidade.
- **Cardápio do Bandeirão (Geração/Análise de Sentimento):** Analisar avaliações do Restaurante Universitário (RU) coletadas nas redes sociais para classificar o nível de satisfação por dia da semana, ou até mesmo fazer o *fine-tuning* de um modelo gerativo (como o GPT-2) para sugerir cardápios fictícios com base no histórico do RU.
- **Match de Projetos de Extensão:** Uma ferramenta em que o aluno digita seus interesses e habilidades, e o modelo utiliza *Sentence-BERT* para calcular a similaridade por cosseno com os editais de projetos de extensão ou de iniciação científica abertos, ranqueando as melhores oportunidades.

## 3 DIRETRIZES E LIMITES

Para garantir que o projeto seja viável e possa ser concluído dentro do prazo, as seguintes regras são inegociáveis:

1. **Requisito Tecnológico:** O projeto **deve** envolver o *fine-tuning* de um modelo pré-treinado ou o uso de *embeddings* gerados por esses modelos (ex: BERT, Sentence-BERT, RoBERTa). O uso exclusivo de chamadas de API para modelos comerciais, sem treinamento ou adaptação local, não será aceito.
2. **Escopo da Tarefa:** Escolham **apenas uma** tarefa primária (ex: Classificação, *Question Answering* extrativo, ou Busca Semântica). Tentar fazer um assistente de conversação aberto resultará em falha no prazo.

3. **Tamanho dos Dados:** Como utilizaremos infraestrutura gratuita (como o Google Colab com GPU T4), a base de dados deve ser viável. Mire em *datasets* com algumas centenas a poucos milhares de exemplos. Priorizem a qualidade e a curadoria dos dados em vez do volume bruto.
4. **Idioma:** Como muitos problemas locais estão em português, o uso de modelos pré-treinados em nosso idioma (como o `neuralmind/bert-base-portuguese-cased`) é fortemente recomendado.

## 4 ENTREGÁVEIS

Vocês deverão entregar um pacote contendo:

1. **Código Fonte (Jupyter Notebook / Colab):** O notebook deve ser autossuficiente, com células de texto (Markdown) que expliquem o raciocínio, o tratamento dos dados, o loop de treinamento e a avaliação.
2. **Artigo Curto (Relatório Técnico):** Um documento (artigo) em LaTeX de 4 a 6 páginas contendo:
  - Introdução e motivação do problema.
  - Descrição e análise exploratória da base de dados.
  - Metodologia (arquitetura do modelo e estratégia de *fine-tuning*).
  - Resultados, métricas de avaliação e discussão dos erros do modelo.
3. **Demonstração (Opcional - Ponto Extra):** Uma interface gráfica simples, construída com bibliotecas como `Gradio` ou `Streamlit`, para interagir com o modelo treinado.

## 5 CRITÉRIOS DE AVALIAÇÃO

A nota do grupo será composta pelos seguintes critérios:

- **Originalidade e Impacto (20%):** A utilidade do problema escolhido e a criatividade na formulação da solução.
- **Qualidade e Curadoria dos Dados (20%):** Como a base foi obtida, limpa e preparada para o modelo (o tratamento de dados textuais do mundo real é fundamental).
- **Rigor Técnico na Implementação (40%):** Uso correto das bibliotecas (PyTorch, Transformers), ausência de vazamento de dados (*data leakage* entre treino e teste), correta manipulação de tensores.

- **Avaliação e Análise Crítica (20%):** Uso de métricas de desempenho adequadas (Acurácia, F1-Score). Mais importante do que ter um modelo com 99% de acurácia é ter uma seção de análise que mostre *onde* e *por que* o modelo erra.
- Além disso, teremos duas datas (a serem definidas) para a **apresentação oral dos trabalhos (10 pontos)**.

*Boa sorte!* A área de Inteligência Artificial é construída por tentativa, erro e experimentação. Sejam ousados nas ideias e rigorosos no código.